



ESCUELA DE INGENIERÍA DE FUENLABRADA

GRADO EN INGENIERÍA DE
ROBÓTICA SOFTWARE

TRABAJO FIN DE GRADO

IA EXPLICATIVA APLICADA A LA DETECCIÓN
DE EMOCIONES A TRAVÉS DE SEÑALES EEG

Autor: Liam Saborido Sueiro

Tutor: Álvaro García López

Co-Tutor: Julio Salvador Lora Millán

Curso académico 2025-2026



Este trabajo se distribuye bajo los términos de la licencia internacional CC BY-SA International License (Creative Commons Attribution-ShareAlike 4.0). Usted es libre de *(a) compartir*: copiar y redistribuir el material en cualquier medio o formato para cualquier propósito, incluso comercialmente; y *(b) adaptar*: remezclar, transformar y construir a partir del material para cualquier propósito, incluso comercialmente. La licenciente no puede revocar estas libertades en tanto usted siga los términos de la licencia:

- *Atribución.* Usted debe dar crédito de manera adecuada, brindar un enlace a la licencia, e indicar si se han realizado cambios. Puede hacerlo en cualquier forma razonable, pero no de forma tal que sugiera que usted o su uso tienen el apoyo de la licenciente.
- *Compartir igual.* Si remezcla, transforma o crea a partir del material, debe distribuir su contribución bajo la misma licencia del original.

No hay restricciones adicionales — No puede aplicar términos legales ni medidas tecnológicas que restrinjan legalmente a otras a hacer cualquier uso permitido por la licencia.

Agradecimientos

Quiero dar las gracias a todas las personas que han estado conmigo durante estos años. A mis padres, Susana y José, por su ayuda económica y emocional, y por confiar en mí incluso cuando yo no lo tenía tan claro. A mi hermana, Xiana, que siempre me ha dado los mejores consejos, especialmente en una etapa en la que tuve que aprender muchas cosas. A mi pareja, Ioana, por convertir muchos días malos en momentos buenos, hacerme reír cuando más lo necesitaba y apoyarme incondicionalmente. Y a mis amigos que siempre me recordaron que no todo era estudiar o preocuparse.

También quiero agradecer a las personas involucradas en la formación del conjunto de datos en la Universidad Complutense. Sin ese trabajo previo, literalmente me habría sido imposible realizar este proyecto. La creación de un conjunto de datos así requiere mucho tiempo, y gran parte de ese esfuerzo no siempre se ve cuando uno trabaja con los datos ya preparados. Y, obviamente, a mi tutor, Álvaro, por su guía, su tiempo y su ayuda durante el desarrollo de este trabajo.

Este trabajo lleva mi nombre, pero no habría llegado a hacerlo sin todos vosotros...

A mi familia, mi pareja y mis amigos

Madrid, 1 de Mayo de 2026

Liam

Resumen

Aun no

Acrónimos

GSR respuesta galvánica de la piel

EMG electromiografía

FC frecuencia cardíaca

FR frecuencia respiratoria

EEG electroencefalografía

fMRI resonancia magnética funcional

PET tomografía por emisión de positrones

Índice general

1. Introducción	1
1.1. Contexto y motivación	1
1.2. Electroencefalografía como fuente de información afectiva	2
1.3. Reconocimiento automático de emociones	2
1.4. IA de caja blanca e interpretabilidad en señales biomédicas	3
1.5. Estructura de la memoria	4
2. Objetivos y planificación	5
2.1. Descripción y objetivo	5
2.2. Requisitos	5
2.3. Metodología de trabajo	7
2.4. Planificación y seguimiento	8
3. Plataforma de desarrollo	9
4. Diseño	10
4.1. Snippets	10
4.2. Verbatim	10
4.3. Ecuaciones	11
4.4. Tablas o cuadros	11
5. Conclusiones	13
5.1. Conclusiones	13
5.2. Corrector ortográfico	14
Bibliografía	15

Índice de figuras

Índice de tablas

4.1. Parámetros intrínsecos de la cámara	12
--	----

Listado de códigos

4.1. Función para buscar elementos 3D en la imagen	10
4.2. Cómo usar un Slider	11

Listado de ecuaciones

4.1. Ejemplo de ecuación con fracciones	11
4.2. Ejemplo de ecuación con array y letras y símbolos especiales	11

Índice de tablas

Capítulo 1

Introducción

Este capítulo presenta la idea general, la motivación detrás del tema y los conceptos principales en los que se basa. Se habla de la electroencefalografía como fuente de información para detectar emociones, del reconocimiento automático de emociones y de la importancia de usar modelos que se puedan interpretar. Por último, se explica cómo está organizada la memoria.

1.1. Contexto y motivación

La electroencefalografía destaca por su capacidad para extraer datos de un órgano tan delicado como el cerebro sin necesidad de realizar una intervención invasiva. Esto la convierte en una herramienta muy valiosa en la neurología, ya sea para diagnosticar tumores y lesiones cerebrales, evaluar el deterioro cognitivo o incluso detectar emociones [1].

Cuando era pequeño me hicieron una prueba del sueño en la que me colocaron electrodos con una pasta adhesiva bastante difícil de quitar y me monitorizaron durante toda la noche. Me llamó mucho la atención: ¿cómo podía un médico mirar todos esos “garabatos” llamados señales y entender qué pasaba en mi cabeza?

Con el tiempo, esa curiosidad se juntó con mi interés por la inteligencia artificial y su uso en la medicina. Al ver cómo otras personas creaban modelos capaces de detectar tumores, me pregunté si también sería posible hacer algo parecido con electroencefalogramas. La idea no es sustituir a los médicos, sino crear una herramienta que pueda ayudarles a interpretar mejor grandes cantidades de datos y aportar información útil de forma automática y fiable.

Este trabajo se centra en el reconocimiento de emociones mediante señales de electroencefalografía (EEG), dando importancia no solo a los resultados obtenidos, sino también a la interpretación de los modelos. En el ámbito biomédico, no basta con que un modelo clasifique bien: también es necesario entender qué información está utilizando y si sus decisiones pueden explicarse de forma clara.

1.2. Electroencefalografía como fuente de información afectiva

Desde siempre, las emociones se han intentado interpretar a partir de lo que una persona dice, sus gestos o sus expresiones faciales. Sin embargo, en un contexto médico esto no siempre es suficiente, ya que una persona puede no expresar exactamente lo que siente. En consecuencia, existen otras formas de estudiar los estados emocionales mediante señales fisiológicas y cerebrales, como la respuesta galvánica de la piel (GSR), la electromiografía (EMG), la frecuencia cardíaca (FC), la frecuencia respiratoria (FR), la EEG, la resonancia magnética funcional (fMRI) o la tomografía por emisión de positrones (PET) [2].

La EEG permite medir la actividad eléctrica del cerebro colocando electrodos sobre el cuero cabelludo. Aunque no muestra directamente lo que ocurre en cada neurona y no tiene tanta precisión espacial como otras técnicas, sí permite observar cambios muy rápidos en la actividad cerebral. Trabajar con señales EEG también tiene sus dificultades, ya que se registran con una amplitud muy baja y pueden verse afectadas por distintas fuentes de ruido. Estos ruidos, conocidos como artefactos, pueden producirse por movimientos musculares, movimientos oculares o parpadeos. Además, en el reconocimiento de emociones no basta con obtener una señal y clasificarla directamente, ya que es necesario comprobar que los cambios observados están realmente relacionados con el estado emocional y no con otros factores externos. Por ello la obtención de estas señales debe realizarse en un entorno controlado y acompañarse de técnicas que permitan reducir o eliminar el ruido presente en los datos [2].

El interés de utilizar señales de EEG está en que permiten observar cómo varía la actividad cerebral ante distintos estímulos emocionales. Al registrar estas respuestas, es posible analizar los datos obtenidos y buscar patrones que ayuden a diferenciar unos estados emocionales de otros. Esto permite plantear el reconocimiento de emociones no solo como un problema de clasificación, sino también como una forma de estudiar qué información de la señal cerebral está relacionada con cada emoción.

1.3. Reconocimiento automático de emociones

El reconocimiento automático de emociones consiste en utilizar datos y modelos computacionales para identificar el estado emocional de una persona. Con ese objetivo, primero se obtiene algún tipo de información del usuario, después se procesan esos

datos y finalmente se entrena un modelo capaz de asociar ciertos patrones con una emoción concreta.

Esta información puede obtenerse de distintas formas. Algunos enfoques se basan en señales externas, como la expresión facial o la voz: en el primer caso, se analizan imágenes o vídeos para extraer características del rostro y clasificar la emoción asociada; en el segundo, se estudian características acústicas del habla, como el tono, la intensidad o el ritmo, para relacionarlas con distintos estados emocionales [3]. Otros enfoques utilizan señales fisiológicas o cerebrales, que permiten estudiar respuestas internas del organismo y no dependen únicamente de cómo la persona expresa la emoción hacia el exterior [4, 2].

El problema se plantea como una tarea de clasificación a partir de señales de EEG. En concreto, se busca distinguir entre tres estados emocionales: alegría, tristeza y estado neutro. Estas clases permiten comparar una emoción positiva, una emoción negativa y una situación sin una carga emocional tan marcada, con el objetivo de analizar si existen diferencias en la señal cerebral que ayuden a separarlas.

1.4. IA de caja blanca e interpretabilidad en señales biomédicas

En el análisis de señales biomédicas, obtener una buena métrica no siempre es suficiente. Un modelo puede conseguir una alta precisión, pero si no se entiende en qué información se basa para tomar sus decisiones, resulta más difícil confiar en sus resultados. Esto es especialmente importante en contextos médicos, donde interesa saber si el modelo está utilizando patrones coherentes de la señal o si, por el contrario, está aprendiendo ruido, artefactos o relaciones poco fiables.

Las inteligencias artificiales de caja blanca o explicables son modelos de aprendizaje automático cuyo funcionamiento puede analizarse de forma más directa. A diferencia de los modelos de caja negra, en los que normalmente solo se observan la entrada y la salida, estos modelos permiten entender mejor qué variables han influido en la decisión final. Esto no significa que sean simples o poco útiles, sino que su estructura facilita interpretar cómo se llega a una predicción. Un clasificador que todos conocemos y no lo sabemos es el árbol de decisión, esta inteligencia.^{es} la que usa el conocido juego Akinator¹, donde va tomando decisiones a partir de una serie de condiciones. En este tipo de modelos es más fácil seguir el razonamiento que lleva a una determinada salida [5].

¹<https://akinator.com/>

Por este motivo, la interpretabilidad tiene un papel importante, no se busca únicamente entrenar un modelo capaz de clasificar emociones, sino también comprender qué información de la señal está utilizando para hacerlo. En el caso de señales de EEG, esto resulta especialmente útil, ya que permite estudiar qué canales, bandas espectrales o características de la señal tienen más peso en la clasificación de una emoción. Esta idea está relacionada con la necesidad de emplear modelos interpretables en decisiones de alto impacto, especialmente en áreas como la salud, donde entender el comportamiento del modelo puede ser tan importante como el resultado obtenido [6].

1.5. Estructura de la memoria

Capítulo 2

Objetivos y planificación

En este capítulo se presenta el planteamiento del problema que se quiere abordar, así como los objetivos principales. También se describen los requisitos que debe cumplir la solución desarrollada, la metodología seguida durante el proyecto y la planificación utilizada para organizar las distintas fases del trabajo. De esta forma, se establece una visión general de qué se pretende conseguir y cómo se ha llevado a cabo.

2.1. Descripción y objetivo

Tras haber presentado el contexto general del reconocimiento de emociones mediante señales de EEG, este trabajo se centra en llevar esa idea a un caso concreto. El objetivo es desarrollar un sistema capaz de analizar señales cerebrales y utilizarlas para distinguir entre tres estados emocionales: alegría, tristeza y estado neutro.

La elección de estas tres clases permite comparar una emoción positiva, una emoción negativa y una situación más neutral. A partir de las señales registradas, se pretende aplicar un proceso completo que incluya el tratamiento de los datos, la extracción de información relevante y el entrenamiento de modelos de aprendizaje automático.

El objetivo principal no es únicamente obtener un modelo que clasifique correctamente las emociones, sino también analizar qué información de la señal influye más en esa clasificación. Para ello, se dará importancia a la interpretabilidad de los modelos, con el fin de estudiar qué características de la señales pueden estar más relacionadas con cada estado emocional.

2.2. Requisitos

Para alcanzar los objetivos planteados, el trabajo debe cumplir una serie de requisitos relacionados con el funcionamiento del sistema y con la interpretación de los resultados obtenidos. Por un lado, el sistema debe ser capaz de procesar señales

de EEG y entrenar modelos de clasificación. Por otro lado, debe permitir analizar qué información de la señal influye en las decisiones tomadas por dichos modelos.

Requisitos funcionales

- El sistema debe permitir trabajar con señales de EEG asociadas a los estados emocionales considerados en el trabajo: alegría, tristeza y estado neutro.
- Debe permitir organizar los datos tanto de forma general como separando la información correspondiente a cada sujeto.
- Debe incluir una fase de preprocesado de las señales de EEG, con el objetivo de eliminar el ruido y preparar los datos antes de su análisis.
- Debe permitir extraer características relevantes de las señales, teniendo en cuenta la información procedente de distintos canales y bandas espectrales.
- Debe entrenar y evaluar un modelo general utilizando datos de varios sujetos, con el objetivo de analizar el comportamiento global del sistema.
- Debe entrenar y evaluar modelos individuales por sujeto, debido a la variabilidad existente entre las señales de distintas personas.
- Debe permitir comparar los resultados obtenidos entre el enfoque general y el enfoque individual.
- Debe evaluar el rendimiento de los modelos mediante métricas adecuadas para tareas de clasificación.

Requisitos de explicabilidad e interpretación

- El sistema debe permitir analizar qué características de la señal tienen mayor importancia en la clasificación de emociones.
- Debe permitir estudiar la influencia de los distintos canales de EEG utilizados durante el entrenamiento.
- Debe permitir analizar la importancia de las bandas espectrales extraídas de la señal.
- Debe generar una representación topográfica general que ayude a visualizar qué zonas del cuero cabelludo tienen mayor relevancia en el análisis realizado.

- Los resultados obtenidos deben presentarse de forma comprensible, no solo como métricas numéricas, sino también mediante análisis que ayuden a interpretar el comportamiento del modelo.

2.3. Metodología de trabajo

La metodología seguida en este trabajo se ha organizado de forma progresiva, comenzando por una revisión de la literatura relacionada con el reconocimiento de emociones mediante señales de EEG, el preprocesado de este tipo de señales, la extracción de características y el uso de modelos interpretables. Esta revisión permitió entender mejor el problema y tomar decisiones sobre las técnicas más adecuadas para aplicar en el desarrollo del trabajo.

Una vez situado el contexto, se llevó a cabo un análisis inicial del conjunto de datos proporcionado por el tutor, el cual fue registrado previamente con sujetos reales. En esta fase se estudió la estructura de los datos, los sujetos disponibles, las clases emocionales consideradas y la forma en la que estaban organizadas las señales. A partir de este análisis, se prepararon los datos para poder trabajar con ellos de forma adecuada en las siguientes fases.

Se realizó el preprocesado de las señales de EEG, con el objetivo de preparar los datos antes de su análisis. Después se llevó a cabo la extracción de características, teniendo en cuenta información procedente de distintos canales y bandas espectrales. Estas características fueron utilizadas como entrada para los modelos de aprendizaje automático.

Antes del entrenamiento de los modelos, se aplicaron técnicas de análisis de datos y algoritmos de separabilidad para estudiar si las características extraídas permitían diferenciar entre las emociones consideradas. Esta fase sirvió para comprender mejor la distribución de los datos y valorar qué información podía ser más útil para la clasificación.

Finalmente, se entrenaron y evaluaron distintos clasificadores, comparando su rendimiento y analizando sus resultados. Además de estudiar la capacidad de los modelos para clasificar las emociones, también se prestó atención a la interpretabilidad, con el objetivo de entender qué características, canales o bandas tenían mayor influencia en las decisiones tomadas por los modelos.

2.4. Planificación y seguimiento

La planificación del trabajo se organizó en distintas tareas principales: revisión bibliográfica, análisis del conjunto de datos, preprocesado de las señales, extracción de características, análisis de separabilidad, entrenamiento de modelos e interpretación de los resultados. Esta división permitió avanzar de forma ordenada y controlar mejor el progreso del proyecto.

El seguimiento del trabajo se realizó mediante revisiones semanales con el tutor. En ellas comentaba los avances realizados, se resolvían dudas y se validaban las decisiones tomadas en cada fase. El proceso seguido consistía primero en leer y estudiar la información necesaria para ubicarme en cada parte del proyecto; después, comentar con el tutor las ideas aprendidas y el plan de acción propuesto; y, finalmente, implementar la solución y corregirla en función de los resultados obtenidos y del feedback recibido.

Para organizar las tareas se siguió una metodología inspirada en el método *Getting Things Done*. Las tareas se dividieron en acciones concretas y manejables, de forma que cada fase del trabajo tuviera objetivos claros. Así, el proyecto fue avanzando por bloques: primero el preprocesado, después la extracción de características, el análisis de separabilidad, el entrenamiento de modelos y, por último, la interpretación y documentación de los resultados.

Esta forma de trabajo permitió mantener un seguimiento continuo del proyecto, detectar problemas de forma temprana y ajustar el planteamiento cuando fue necesario. Además, las reuniones periódicas ayudaron a comprobar que cada decisión técnica estuviera alineada con los objetivos del trabajo.

Capítulo 3

Plataforma de desarrollo

Quizás algún fragmento de libro inspirador...

Autor, Título

Escribe aquí un párrafo explicando brevemente lo que vas a contar en este capítulo. En este capítulo, explica qué has usado a nivel hardware y software para poder desarrollar tu trabajo: librerías, sistemas operativos, plataformas, entornos de desarrollo, etc.

Capítulo 4

Diseño

Quizás algún fragmento de libro inspirador...

Autor, *Título*

Escribe aquí un párrafo explicando brevemente lo que vas a contar en este capítulo. En este capítulo (y quizás alguno más) es donde, por fin, describes detalladamente qué has hecho y qué experimentos has llevado a cabo para validar tus desarrollos.

4.1. Snippets

Puede resultar interesante, para clarificar la descripción, mostrar fragmentos de código (o *snippets*) ilustrativos. En el Código 4.1 vemos un ejemplo escrito en C++.

```
void Memory::hypothesizeParallelograms () {
    for(it1 = this->controller->segmentMemory.begin(); it1++) {
        squareFound = false; it2 = it1; it2++;
        while ((it2 != this->controller->segmentMemory.end()) && (!squareFound))
        {
            if (geometry::haveACommonVertex((*it1),(*it2),&square)) {
                dist1 = geometry::distanceBetweenPoints3D ((*it1).start, (*it1).end);
                dist2 = geometry::distanceBetweenPoints3D ((*it2).start, (*it2).end);
            }
        }
        // [...]
    }
}
```

Código 4.1: Función para buscar elementos 3D en la imagen

En el Código 4.2 vemos un ejemplo escrito en Python.

4.2. Verbatim

Para mencionar identificadores usados en el código —como nombres de funciones o variables— en el texto, usa el entorno literal o verbatim

```
def mostrarValores():
    print (w1.get(), w2.get())

master = Tk()
w1 = Scale(master, from_=0, to=42)
w1.pack()
w2 = Scale(master, from_=0, to=200, orient=HORIZONTAL)
w2.pack()
Button(master, text='Show', command=mostrarValores).pack()

mainloop()
```

Código 4.2: Cómo usar un Slider

`hypothesizeParallelograms()`. También se puede usar este entorno para varias líneas, como se ve a continuación:

```
void Memory::hypothesizeParallelograms () {
    // add your code here
}
```

4.3. Ecuaciones

Si necesitas insertar alguna ecuación, puedes hacerlo. Al igual que las figuras, no te olvides de referenciarlas. A continuación se exponen algunas ecuaciones de ejemplo: Ecuación 4.1 y Ecuación 4.2.

$$H = 1 - \frac{\sum_{i=0}^N \frac{(\frac{d_{js} + d_{je}}{2})}{N}}{M} \quad (4.1)$$

Ecuación 4.1: Ejemplo de ecuación con fracciones

$$v(entrada) = \begin{cases} 0 & \text{if } \epsilon_t < 0,1 \\ K_p \cdot (T_t - T) & \text{if } 0,1 \leq \epsilon_t < M_t \\ K_p \cdot M_t & \text{if } M_t < \epsilon_t \end{cases} \quad (4.2)$$

Ecuación 4.2: Ejemplo de ecuación con array y letras y símbolos especiales

4.4. Tablas o cuadros

Si necesitas insertar una tabla, hazlo dignamente usando las propias tablas de L^AT_EX, no usando pantallazos e insertándolas como figuras... En el Cuadro 4.1 vemos

un ejemplo.

Parámetros	Valores
Tipo de sensor	Sony IMX219PQ[7] CMOS 8-Mpx
Tamaño del sensor	3.674 x 2.760 mm (1/4" format)
Número de pixels	3280 x 2464 (active pixels)
Tamaño de pixel	1.12 x 1.12 μm
Lente	f=3.04 mm, f/2.0
Ángulo de visión	62.2 x 48.8 degrees
Lente SLR equivalente	29 mm

Tabla 4.1: Parámetros intrínsecos de la cámara

Capítulo 5

Conclusiones

Quizás algún fragmento de libro inspirador...

Autor, *Título*

Escribe aquí un párrafo explicando brevemente lo que vas a contar en este capítulo, que básicamente será una recapitulación de los problemas que has abordado, las soluciones que has prouesto, así como los experimentos llevados a cabo para validarlos. Y con esto, cierras la memoria.

5.1. Conclusiones

Enumera los objetivos y cómo los has cumplido.

Enumera también los requisitos implícitos en la consecución de esos objetivos, y cómo se han satisfecho.

No olvides dedicar un par de párrafos para hacer un balance global de qué has conseguido, y por qué es un avance respecto a lo que tenías inicialmente. Haz mención expresa de alguna limitación o peculiaridad de tu sistema y por qué es así. Y también, qué has aprendido desarrollando este trabajo.

Por último, añade otro par de párrafos de líneas futuras; esto es, cómo se puede continuar tu trabajo para abarcar una solución más amplia, o qué otras ramas de la investigación podrían seguirse partiendo de este trabajo, o cómo se podría mejorar para conseguir una aplicación real de este desarrollo (si es que no se ha llegado a conseguir).

5.2. Corrector ortográfico

Una vez tengas todo, no olvides pasar el corrector ortográfico de L^AT_EXa todos tus ficheros *.tex*. En **Windows**, el propio editor **TeXworks** incluye el corrector. En **Linux**, usa **aspell** ejecutando el siguiente comando en tu terminal:

```
aspell --lang=es --mode=tex check capitulo1.tex
```

Bibliografía

- [1] Mayo Clinic. Electroencefalografía (EEG), 2024. <https://www.mayoclinic.org/es/tests-procedures/eeg/about/pac-20393875>.
- [2] Soraia M. Alarcão and Manuel J. Fonseca. Emotions recognition using eeg signals: A survey. *IEEE Transactions on Affective Computing*, 10(3):374–393, 2019. <https://ieeexplore.ieee.org/abstract/document/7946165>.
- [3] Isaac Martín de Diego, Ángel Serrano, Cristina Conde, and Enrique Cabello. Técnicas de reconocimiento automático de emociones. *Teoría de la Educación: Educación y Cultura en la Sociedad de la Información*, 7(2):92–106, 2006. <https://revistas.usal.es/tres/index.php/eks/article/view/19413/19414>.
- [4] Lin Shu, Jinyan Xie, Mingyue Yang, Ziyi Li, Zhenqi Li, Dan Liao, Xiangmin Xu, and Xinyi Yang. A review of emotion recognition using physiological signals. *Sensors*, 18(7):2074, 2018. <https://www.mdpi.com/1424-8220/18/7/2074>.
- [5] Christoph Molnar. *Interpretable Machine Learning*. 2 edition, 2022. <https://christophm.github.io/interpretable-ml-book/>.
- [6] Cynthia Rudin. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1:206–215, 2019. <https://www.nature.com/articles/s42256-019-0048-x>.