



ESCUELA DE INGENIERÍA DE FUENLABRADA

GRADO EN INGENIERÍA DE
ROBÓTICA SOFTWARE

TRABAJO FIN DE GRADO

IA EXPLICATIVA APLICADA A LA DETECCIÓN
DE EMOCIONES A TRAVÉS DE SEÑALES EEG

Autor: Liam Saborido Sueiro

Tutor: Álvaro García López

Co-Tutor: Julio Salvador Lora Millán

Curso académico 2025-2026



Este trabajo se distribuye bajo los términos de la licencia internacional CC BY-SA International License (Creative Commons Attribution-ShareAlike 4.0). Usted es libre de *(a) compartir*: copiar y redistribuir el material en cualquier medio o formato para cualquier propósito, incluso comercialmente; y *(b) adaptar*: remezclar, transformar y construir a partir del material para cualquier propósito, incluso comercialmente. La licenciante no puede revocar estas libertades en tanto usted siga los términos de la licencia:

- *Atribución.* Usted debe dar crédito de manera adecuada, brindar un enlace a la licencia, e indicar si se han realizado cambios. Puede hacerlo en cualquier forma razonable, pero no de forma tal que sugiera que usted o su uso tienen el apoyo de la licenciante.
- *Compartir igual.* Si remezcla, transforma o crea a partir del material, debe distribuir su contribución bajo la misma licencia del original.
No hay restricciones adicionales — No puede aplicar términos legales ni medidas tecnológicas que restrinjan legalmente a otras a hacer cualquier uso permitido por la licencia.

Agradecimientos

Quiero dar las gracias a todas las personas que han estado conmigo durante estos años. A mis padres, Susana y José, por su ayuda económica y emocional, y por confiar en mí incluso cuando yo no lo tenía tan claro. A mi hermana, Xiana, que siempre me ha dado los mejores consejos, especialmente en una etapa en la que tuve que aprender muchas cosas. A mi pareja, Ioana, por convertir muchos días malos en momentos buenos, hacerme reír cuando más lo necesitaba y apoyarme incondicionalmente. Y a mis amigos que siempre me recordaron que no todo era estudiar o preocuparse.

También quiero agradecer a las personas involucradas en la formación del conjunto de datos en la Universidad Complutense. Sin ese trabajo previo, literalmente me habría sido imposible realizar este proyecto. La creación de un conjunto de datos así requiere mucho tiempo, y gran parte de ese esfuerzo no siempre se ve cuando uno trabaja con los datos ya preparados. Y, obviamente, a mi tutor, Álvaro, por su guía, su tiempo y su ayuda durante el desarrollo de este trabajo.

Este trabajo lleva mi nombre, pero no habría llegado a hacerlo sin todos vosotros...

A mi familia, mi pareja y mis amigos

Madrid, 1 de Mayo de 2026

Liam

Resumen

Aun no

Acrónimos

GSR respuesta galvánica de la piel

EMG electromiografía

FC frecuencia cardíaca

FR frecuencia respiratoria

EEG electroencefalografía

fMRI resonancia magnética funcional

PET tomografía por emisión de positrones

SHAP *SHapley Additive exPlanations*

Índice general

1. Introducción	1
1.1. Contexto y motivación	1
1.2. Electroencefalografía como fuente de información afectiva	2
1.3. Reconocimiento automático de emociones	3
1.4. IA de caja blanca e interpretabilidad en señales biomédicas	3
1.5. Estructura de la memoria	4
2. Objetivos y planificación	5
2.1. Descripción y objetivo	5
2.2. Requisitos	6
2.3. Metodología de trabajo	7
2.4. Planificación y seguimiento	8
3. Fundamentos teóricos	9
3.1. Señales EEG y posicionamiento de electrodos	9
3.2. Bandas espectrales	11
3.3. Emociones y actividad cerebral: alegría, tristeza y estado neutro	12
3.4. Aprendizaje automático aplicado a EEG	14
3.4.1. Modelos interpretables frente a modelos de caja negra	15
3.4.2. Clasificadores	16

3.4.3. Estrategia de evaluación y validación cruzada	18
3.4.4. Métricas	20
3.5. Técnicas de explicación	23
Bibliografía	25

Índice de figuras

3.1. Principales lóbulos de la corteza cerebral. Fuente: [1].	10
3.2. Sistema internacional 10-20 para la colocación de electrodos EEG. Fuente: [2].	11
3.3. Representación simplificada de emociones según valencia y arousal. Adaptado de [3].	13
3.4. Comparación entre regresión logística binaria y multiclase.	17
3.5. Ejemplo de estructura de árbol de decisión. Fuente: [4].	17
3.6. Esquema de validación cruzada <i>k-fold</i> . Fuente: [5].	19
3.7. Ejemplo de matriz de confusión binaria. Fuente: [6].	21
3.8. Ejemplo de topomaps por banda espectral para la clase alegría.	23
3.9. Ejemplo de importancia de características mediante valores SHAP.	24

Índice de tablas

3.1. Bandas espectrales principales de la señal EEG.	12
--	----

Listado de códigos

Listado de ecuaciones

3.1. Probabilidad estimada por una regresión logística binaria.	16
3.2. Promedio de una métrica en validación cruzada <i>k-fold</i>	19
3.3. Exactitud en clasificación multiclase a partir de la matriz de confusión.	21
3.4. Precisión, recall y F1-score para una clase <i>c</i>	22
3.5. F1 macro como promedio no ponderado del F1-score por clase.	22

Capítulo 1

Introducción

Este capítulo presenta la idea general, la motivación detrás del tema y los conceptos principales en los que se basa. Se habla de la electroencefalografía como fuente de información para detectar emociones, del reconocimiento automático de emociones y de la importancia de usar modelos que se puedan interpretar. Por último, se explica cómo está organizada la memoria.

1.1. Contexto y motivación

La electroencefalografía destaca por su capacidad para extraer datos de un órgano tan delicado como el cerebro sin necesidad de realizar una intervención invasiva. Esto la convierte en una herramienta muy valiosa en la neurología, ya sea para diagnosticar tumores y lesiones cerebrales, evaluar el deterioro cognitivo o incluso detectar emociones [7].

Cuando era pequeño me hicieron una prueba del sueño en la que me colocaron electrodos con una pasta adhesiva bastante difícil de quitar y me monitorizaron durante toda la noche. Me llamó mucho la atención: ¿cómo podía un médico mirar todos esos “garabatos” llamados señales y entender qué pasaba en mi cabeza?

Con el tiempo, esa curiosidad se juntó con mi interés por la inteligencia artificial y su uso en la medicina. Al ver cómo otras personas creaban modelos capaces de detectar tumores, me pregunté si también sería posible hacer algo parecido con electroencefalogramas. La idea no es sustituir a los médicos, sino crear una herramienta que pueda ayudarles a interpretar mejor grandes cantidades de datos y aportar información útil de forma automática y fiable.

Este trabajo se centra en el reconocimiento de emociones mediante señales de

electroencefalografía (EEG), dando importancia no solo a los resultados obtenidos, sino también a la interpretación de los modelos. En el ámbito biomédico, no basta con que un modelo clasifique bien: también es necesario entender qué información está utilizando y si sus decisiones pueden explicarse de forma clara.

1.2. Electroencefalografía como fuente de información afectiva

Desde siempre, las emociones se han intentado interpretar a partir de lo que una persona dice, sus gestos o sus expresiones faciales. Sin embargo, en un contexto médico esto no siempre es suficiente, ya que una persona puede no expresar exactamente lo que siente. En consecuencia, existen otras formas de estudiar los estados emocionales mediante señales fisiológicas y cerebrales, como la respuesta galvánica de la piel (GSR), la electromiografía (EMG), la frecuencia cardíaca (FC), la frecuencia respiratoria (FR), la EEG, la resonancia magnética funcional (fMRI) o la tomografía por emisión de positrones (PET) [8].

La EEG permite medir la actividad eléctrica del cerebro colocando electrodos sobre el cuero cabelludo. Aunque no muestra directamente lo que ocurre en cada neurona y no tiene tanta precisión espacial como otras técnicas, sí permite observar cambios muy rápidos en la actividad cerebral. Trabajar con señales EEG también tiene sus dificultades, ya que se registran con una amplitud muy baja y pueden verse afectadas por distintas fuentes de ruido. Estos ruidos, conocidos como artefactos, pueden producirse por movimientos musculares, movimientos oculares o parpadeos. Además, en el reconocimiento de emociones no basta con obtener una señal y clasificarla directamente, ya que es necesario comprobar que los cambios observados están realmente relacionados con el estado emocional y no con otros factores externos. Por ello la obtención de estas señales debe realizarse en un entorno controlado y acompañarse de técnicas que permitan reducir o eliminar el ruido presente en los datos [8].

El interés de utilizar señales de EEG está en que permiten observar cómo varía la actividad cerebral ante distintos estímulos emocionales. Al registrar estas respuestas, es posible analizar los datos obtenidos y buscar patrones que ayuden a diferenciar unos estados emocionales de otros. Esto permite plantear el reconocimiento de emociones no solo como un problema de clasificación, sino también como una forma de estudiar

qué información de la señal cerebral está relacionada con cada emoción.

1.3. Reconocimiento automático de emociones

El reconocimiento automático de emociones consiste en utilizar datos y modelos computacionales para identificar el estado emocional de una persona. Con ese objetivo, primero se obtiene algún tipo de información del usuario, después se procesan esos datos y finalmente se entrena un modelo capaz de asociar ciertos patrones con una emoción concreta.

Esta información puede obtenerse de distintas formas. Algunos enfoques se basan en señales externas, como la expresión facial o la voz: en el primer caso, se analizan imágenes o vídeos para extraer características del rostro y clasificar la emoción asociada; en el segundo, se estudian características acústicas del habla, como el tono, la intensidad o el ritmo, para relacionarlas con distintos estados emocionales [9]. Otros enfoques utilizan señales fisiológicas o cerebrales, que permiten estudiar respuestas internas del organismo y no dependen únicamente de cómo la persona expresa la emoción hacia el exterior [10, 8].

1.4. IA de caja blanca e interpretabilidad en señales biomédicas

En el análisis de señales biomédicas, obtener una buena métrica no siempre es suficiente. Un modelo puede conseguir una alta precisión, pero si no se entiende en qué información se basa para tomar sus decisiones, resulta más difícil confiar en sus resultados. Esto es especialmente importante en contextos médicos, donde interesa saber si el modelo está utilizando patrones coherentes de la señal o si, por el contrario, está aprendiendo ruido, artefactos o relaciones poco fiables.

Las inteligencias artificiales de caja blanca o explicables son modelos de aprendizaje automático cuyo funcionamiento puede analizarse de forma más directa. A diferencia de los modelos de caja negra, en los que normalmente solo se observan la entrada y la salida, estos modelos permiten entender mejor qué variables han influido en la decisión final. Esto no significa que sean simples o poco útiles, sino que su estructura facilita interpretar cómo se llega a una predicción. Un clasificador que todos conocemos y no lo sabemos es el árbol de decisión, esta “inteligencia” es la que usa el conocido juego

Akinator¹, donde va tomando decisiones a partir de una serie de condiciones. En este tipo de modelos es más fácil seguir el razonamiento que lleva a una determinada salida [11].

Por este motivo, la interpretabilidad tiene un papel importante, no se busca únicamente entrenar un modelo capaz de clasificar emociones, sino también comprender qué información de la señal está utilizando para hacerlo. En el caso de señales de EEG, esto resulta especialmente útil, ya que permite estudiar qué canales, bandas espectrales o características de la señal tienen más peso en la clasificación de una emoción. Esta idea está relacionada con la necesidad de emplear modelos interpretables en decisiones de alto impacto, especialmente en áreas como la salud, donde entender el comportamiento del modelo puede ser tan importante como el resultado obtenido [12].

1.5. Estructura de la memoria

¹<https://akinator.com/>

Capítulo 2

Objetivos y planificación

En este capítulo se presenta el planteamiento del problema que se quiere abordar, así como los objetivos principales. También se describen los requisitos que debe cumplir la solución desarrollada, la metodología seguida durante el proyecto y la planificación utilizada para organizar las distintas fases del trabajo. De esta forma, se establece una visión general de qué se pretende conseguir y cómo se ha llevado a cabo.

2.1. Descripción y objetivo

Tras haber presentado el contexto general del reconocimiento de emociones mediante señales de EEG, este trabajo se centra en llevar esa idea a un caso concreto. El objetivo es desarrollar un sistema capaz de analizar señales cerebrales y utilizarlas para distinguir entre tres estados emocionales: alegría, tristeza y estado neutro.

La elección de estas tres clases permite comparar una emoción positiva, una emoción negativa y una situación más neutral. A partir de las señales registradas, se pretende aplicar un proceso completo que incluya el tratamiento de los datos, la extracción de información relevante y el entrenamiento de modelos de aprendizaje automático.

El objetivo principal no es únicamente obtener un modelo que clasifique correctamente las emociones, sino también analizar qué información de la señal influye más en esa clasificación. Para ello, se dará importancia a la interpretabilidad de los modelos, con el fin de estudiar qué características de la señales pueden estar más relacionadas con cada estado emocional.

2.2. Requisitos

Para alcanzar los objetivos planteados, el trabajo debe cumplir una serie de requisitos relacionados con el funcionamiento del sistema y con la interpretación de los resultados obtenidos. Por un lado, el sistema debe ser capaz de procesar señales de EEG y entrenar modelos de clasificación. Por otro lado, debe permitir analizar qué información de la señal influye en las decisiones tomadas por dichos modelos.

Requisitos funcionales

- El sistema debe permitir trabajar con señales de EEG asociadas a los estados emocionales considerados en el trabajo: alegría, tristeza y estado neutro.
- Debe permitir organizar los datos tanto de forma general como separando la información correspondiente a cada sujeto.
- Debe incluir una fase de preprocesado de las señales de EEG, con el objetivo de eliminar el ruido y preparar los datos antes de su análisis.
- Debe permitir extraer características relevantes de las señales, teniendo en cuenta la información procedente de distintos canales y bandas espectrales.
- Debe entrenar y evaluar un modelo general utilizando datos de varios sujetos, con el objetivo de analizar el comportamiento global del sistema.
- Debe entrenar y evaluar modelos individuales por sujeto, debido a la variabilidad existente entre las señales de distintas personas.
- Debe permitir comparar los resultados obtenidos entre el enfoque general y el enfoque individual.
- Debe evaluar el rendimiento de los modelos mediante métricas adecuadas para tareas de clasificación.

Requisitos de explicabilidad e interpretación

- El sistema debe permitir analizar qué características de la señal tienen mayor importancia en la clasificación de emociones.

- Debe permitir estudiar la influencia de los distintos canales de EEG utilizados durante el entrenamiento.
- Debe permitir analizar la importancia de las bandas espectrales extraídas de la señal.
- Debe generar una representación topográfica general que ayude a visualizar qué zonas del cuero cabelludo tienen mayor relevancia en el análisis realizado.
- Los resultados obtenidos deben presentarse de forma comprensible, no solo como métricas numéricas, sino también mediante análisis que ayuden a interpretar el comportamiento del modelo.

2.3. Metodología de trabajo

La metodología seguida en este trabajo se ha organizado de forma progresiva, comenzando por una revisión de la literatura relacionada con el reconocimiento de emociones mediante señales de EEG, el preprocesado de este tipo de señales, la extracción de características y el uso de modelos interpretables. Esta revisión permitió entender mejor el problema y definir el enfoque técnico que se iba a seguir.

Una vez situado el contexto, se llevó a cabo un análisis inicial del conjunto de datos proporcionado por el tutor, el cual fue registrado previamente con sujetos reales. En esta fase se estudió la estructura de los datos, los sujetos disponibles, las clases emocionales consideradas y la forma en la que estaban agrupados los registros.

A partir de este análisis, se desarrolló el flujo principal del trabajo. Primero se realizó el preprocesado de las señales de EEG, con el objetivo de preparar los datos antes de su análisis. Después se llevó a cabo la extracción de características, teniendo en cuenta información procedente de distintos canales y bandas espectrales. Estas características fueron utilizadas posteriormente como entrada para los modelos de aprendizaje automático.

Antes del entrenamiento, se aplicaron técnicas de análisis de datos y algoritmos de separabilidad para estudiar si las características extraídas permitían diferenciar entre las emociones consideradas. Esta fase ayudó a comprender mejor la distribución de los datos y a valorar qué información podía ser más útil para la clasificación.

Finalmente, se entrenaron y evaluaron distintos clasificadores. Además de analizar

su rendimiento, también se prestó atención a la interpretabilidad de los resultados, con el objetivo de entender qué características, canales o bandas tenían mayor influencia en las decisiones tomadas por los modelos.

2.4. Planificación y seguimiento

La planificación del trabajo se realizó dividiendo el proyecto en tareas concretas y manejables, siguiendo una metodología inspirada en el método *Getting Things Done*. Esta forma de organización permitió separar el trabajo en bloques claros y avanzar de manera progresiva, evitando abordar todo el proyecto de forma desordenada.

El seguimiento se llevó a cabo de forma semanal mediante tutorías y comunicación por correo electrónico con el tutor. A través de este seguimiento se comentaban los avances realizados, se resolvían dudas y se validaban las decisiones tomadas en cada fase del trabajo. Esto permitió ajustar el planteamiento cuando fue necesario y corregir posibles errores durante el desarrollo.

El proceso seguido en cada bloque fue similar: primero se realizaba una lectura o estudio previo para entender la parte que se iba a trabajar; después, se comentaban con el tutor las ideas aprendidas y el plan de acción; y finalmente se implementaba la solución correspondiente, revisándola en función de los resultados obtenidos y del feedback recibido.

Gracias a esta organización, el proyecto pudo avanzar de forma controlada, manteniendo un seguimiento continuo de las tareas y asegurando que cada decisión técnica estuviera alineada con los objetivos del trabajo.

Capítulo 3

Fundamentos teóricos

En este capítulo se presentan los fundamentos teóricos necesarios para entender el desarrollo del trabajo. Para poder abordar el reconocimiento de emociones mediante EEG, primero es necesario conocer cómo se registran estas señales, qué información pueden aportar sus distintas bandas espectrales y qué relación pueden tener con la actividad emocional. Además, se introducen conceptos relacionados con el preprocesado de señales, el tratamiento de artefactos, el aprendizaje automático aplicado a EEG y las técnicas utilizadas para interpretar los modelos obtenidos.

3.1. Señales EEG y posicionamiento de electrodos

La EEG es una técnica que permite registrar la actividad eléctrica del cerebro mediante electrodos colocados en la cabeza. Lo que se mide realmente no es la actividad de una neurona aislada, sino pequeñas variaciones de voltaje generadas por la actividad conjunta de muchas neuronas, que llegan hasta la superficie de la cabeza y pueden ser captadas por los electrodos.

Estas señales suelen tener una amplitud muy baja, por lo que su registro requiere un equipo específico de adquisición y electrodos distribuidos por distintas zonas del cuero cabelludo. Dependiendo del dispositivo utilizado, los electrodos pueden necesitar gel o pasta conductora para mejorar el contacto con la piel, aunque también existen gorros que emplean electrodos secos o sensores humedecidos con agua mediante pequeñas esponjas.

Durante una grabación, el sujeto normalmente permanece sentado o en reposo mientras se registran las señales, y en estudios de emociones puede ser expuesto a estímulos como imágenes, sonidos o vídeos para observar cómo cambia la actividad cerebral. Aunque no siempre es obligatorio utilizar una sala médica específica, sí es

recomendable realizar la grabación en un entorno controlado, cómodo y con las menores distracciones posibles, ya que factores como el movimiento, los parpadeos, la actividad muscular, la iluminación o la incomodidad pueden introducir ruido en la señal. Por este motivo, el registro no consiste únicamente en colocar electrodos y guardar datos, sino en intentar obtener una señal lo suficientemente limpia y controlada como para que posteriormente pueda analizarse y relacionarse con el estado mental o emocional del sujeto [8].

La corteza cerebral es una de las partes principales del cerebro y suele dividirse en cuatro lóbulos: frontal, temporal, parietal y occipital. Cada uno de ellos está relacionado con funciones diferentes. El lóbulo frontal participa en procesos asociados al pensamiento consciente; el temporal está relacionado con sentidos como el oído y el olfato, además del procesamiento de estímulos complejos como caras o escenas; el parietal integra información procedente de distintos sentidos y participa en la manipulación de objetos; y el occipital está principalmente vinculado con la visión [8]. Aunque la grabación no permita localizar con precisión exacta la actividad de cada región cerebral, la posición de los electrodos ofrece una referencia aproximada de la zona desde la que se está registrando la señal.




Figura 3.1: Principales lóbulos de la corteza cerebral. Fuente: [1].

La colocación de los electrodos no se realiza de forma aleatoria, sino siguiendo sistemas estandarizados que permiten registrar la actividad cerebral de manera ordenada y comparable entre sujetos. Uno de los sistemas más utilizados es el sistema internacional 10-20, en el que las posiciones de los electrodos se calculan a partir de referencias anatómicas de la cabeza, como el nasion, el inion y los puntos preauriculares. El nombre 10-20 hace referencia a que las distancias entre posiciones se establecen como porcentajes del tamaño de la cabeza, lo que permite adaptar el montaje a cada persona.

Además, existen sistemas más densos, como el sistema 10-10 o el montaje estándar 10-05, que añaden posiciones intermedias y permiten trabajar con configuraciones de mayor número de electrodos. En la práctica, los registros de EEG pueden realizarse con montajes de distinta densidad, como 32 o 64 electrodos. Un montaje de 32 canales puede ofrecer una cobertura general, mientras que uno de 64 canales permite recoger información con mayor detalle espacial. [13, 14].




Figura 3.2: Sistema internacional 10-20 para la colocación de electrodos EEG. Fuente: [2].

La nomenclatura de los electrodos indica la zona aproximada en la que se encuentran: F a la frontal, C a la central, T a la temporal, P a la parietal y O a la occipital. Además, la letra z indica posiciones situadas en la línea media, los números impares suelen corresponder al hemisferio izquierdo y los pares al hemisferio derecho. Esta localización es importante porque cada canal recoge información de una zona concreta, por lo que la posición de los electrodos influye directamente en el análisis posterior, especialmente cuando se estudia qué canales o regiones tienen más importancia en la clasificación de emociones.

3.2. Bandas espectrales

La señal de EEG puede analizarse tanto en el dominio temporal como en el dominio frecuencial. En este segundo caso, la señal se descompone en distintos rangos de frecuencia, conocidos como bandas espectrales. Estas bandas permiten estudiar qué parte de la actividad cerebral aparece con mayor presencia en cada momento y facilitan la extracción de características para su posterior uso en modelos de aprendizaje automático. Aunque los límites exactos pueden variar ligeramente según el autor,

normalmente se distinguen cinco bandas principales: delta, theta, alpha, beta y gamma [8].

Banda	Rango aproximado	Asociación general
Delta	1–4 Hz	Se suele relacionar con estados de sueño profundo o baja actividad consciente.
Theta	4–8 Hz	Se asocia a estados de somnolencia, relajación o actividad subconsciente.
Alpha	8–12 Hz	Suele aparecer en estados de relajación, especialmente cuando la persona está despierta pero tranquila.
Beta	12–30 Hz	Se relaciona con estados de mayor actividad mental, atención o concentración.
Gamma	>30 Hz	Se asocia con una actividad cerebral más intensa o procesos de integración de información.

Tabla 3.1: Bandas espectrales principales de la señal EEG.

El análisis por bandas es importante porque muchas veces la información relevante de una señal de EEG no se encuentra directamente en la señal completa, sino en cómo cambia la actividad dentro de determinados rangos de frecuencia. Por ejemplo, en lugar de utilizar únicamente la señal cruda, es habitual calcular características como la potencia de cada banda en distintos canales. De esta forma, el modelo puede trabajar con una representación más compacta y útil de la actividad cerebral.

En el reconocimiento de emociones, estas bandas pueden aportar información relevante, ya que la actividad alpha y la asimetría entre hemisferios se han relacionado con la valencia emocional, mientras que las bandas beta y gamma también aparecen asociadas a la diferenciación de ciertos estados afectivos [8]. Por este motivo, en trabajos de clasificación emocional con EEG es frecuente extraer características a partir de varias bandas espectrales, ya que cada una puede aportar información distinta sobre la respuesta cerebral.

3.3. Emociones y actividad cerebral: alegría, tristeza y estado neutro

Las emociones pueden representarse de distintas formas. Una de ellas es mediante modelos discretos, donde cada emoción se trata como una categoría concreta, por

ejemplo alegría, tristeza, miedo o ira. Otra forma habitual es utilizar modelos dimensionales, en los que las emociones se describen a partir de ejes continuos. Uno de los modelos más utilizados es el de valencia-excitación, donde la valencia indica si la emoción es más positiva o negativa, mientras que la excitación representa el nivel de activación asociado a esa emoción. Desde esta perspectiva, la alegría puede situarse en una zona de valencia positiva, la tristeza en una zona de valencia negativa y el estado neutro en una posición más intermedia, con una carga emocional menos marcada [8].




Figura 3.3: Representación simplificada de emociones según valencia y arousal. Adaptado de [3].

Para detectar estados emocionales a partir de señales de EEG, los estudios analizan cómo varía la actividad cerebral en distintas regiones ante diferentes estímulos, siendo las zonas frontal y parietal las que aparecen con mayor frecuencia como relevantes [8]. A partir de estas observaciones, se extraen características de la señal que se utilizan como entrada a modelos de clasificación. Sin embargo, estas relaciones no constituyen patrones universales, sino tendencias que varían considerablemente entre personas: la respuesta cerebral ante una misma emoción puede diferir de forma notable de un sujeto a otro. Esta variabilidad intersujeto es uno de los principales retos del campo y explica por qué los modelos entrenados con datos de varios sujetos no siempre generalizan bien, lo que justifica también el análisis de modelos individuales por sujeto [15].

De forma general, las emociones positivas suelen asociarse con una mayor actividad relativa en regiones frontales izquierdas, mientras que las emociones negativas se han relacionado con una mayor actividad relativa en regiones frontales derechas. Esta diferencia entre hemisferios se conoce como asimetría frontal y se ha utilizado en distintos estudios como una posible señal relacionada con la valencia emocional. El estado neutro no debería presentar una activación emocional tan marcada, por lo que puede utilizarse como referencia frente a las emociones con mayor carga afectiva [8].

3.4. Aprendizaje automático aplicado a EEG

El aprendizaje automático permite construir modelos capaces de aprender patrones a partir de datos y utilizarlos posteriormente para realizar predicciones sobre nuevos ejemplos. En una tarea de clasificación supervisada, cada muestra de entrada se asocia a una etiqueta conocida durante el entrenamiento. A partir de estos ejemplos, el modelo aprende una relación entre las variables de entrada y la clase correspondiente, con el objetivo de aplicar ese conocimiento a datos no vistos previamente [16].

En el caso de señales de EEG, la entrada del modelo no suele ser la señal completa registrada en el tiempo, ya que esta puede contener ruido, redundancia y una dimensionalidad elevada. Por ello, normalmente se trabaja con una representación basada en características, es decir, con variables numéricas que resumen información relevante de la señal. Estas características pueden describir aspectos temporales, frecuenciales o espaciales de la actividad cerebral, dependiendo del tipo de análisis realizado.

Desde el punto de vista del clasificador, cada muestra queda representada por un conjunto de características y una etiqueta de clase. El modelo intenta encontrar relaciones entre esas características y la clase asociada, de forma que pueda asignar una etiqueta a nuevas muestras. Si las características contienen información discriminativa, las muestras de una misma clase tenderán a presentar cierta similitud entre ellas, mientras que las muestras de clases distintas deberían mostrar diferencias aprovechables por el modelo [17].

Sin embargo, en señales de EEG este proceso no es directo. La actividad cerebral registrada en superficie es compleja, puede verse afectada por artefactos y presenta una variabilidad considerable entre personas. Como consecuencia, dos muestras asociadas a una misma emoción no tienen por qué ser muy parecidas, y dos emociones distintas pueden generar patrones parcialmente solapados. Esta dificultad hace que la evaluación del modelo sea especialmente importante, ya que no basta con que aprenda bien los ejemplos de entrenamiento: debe comprobarse si mantiene un comportamiento adecuado ante datos que no ha utilizado para ajustar sus parámetros.

Además, en señales biomédicas como la EEG, el rendimiento del modelo no es el único aspecto relevante. También interesa analizar qué información está utilizando para tomar sus decisiones y si esa información resulta coherente con el problema estudiado. Por ello, antes de describir los clasificadores utilizados, conviene diferenciar

entre modelos interpretables y modelos de caja negra, ya que esta distinción condiciona la forma en la que pueden analizarse los resultados obtenidos.

3.4.1. Modelos interpretables frente a modelos de caja negra

Un modelo de caja negra es aquel cuyo funcionamiento interno no resulta fácil de seguir por una persona. Aunque se conocen las características que recibe como entrada y la predicción que genera como salida, no siempre es sencillo entender cómo transforma esas variables en una decisión concreta. Esto suele ocurrir en modelos con una estructura compleja, como redes neuronales profundas¹ o métodos de conjunto como Random Forest², donde la relación entre entrada y salida queda distribuida entre numerosos parámetros o transformaciones internas [11]. Un ejemplo conocido de sistema basado en modelos de este tipo es ChatGPT³: el usuario puede observar el texto que introduce y la respuesta que recibe, pero el proceso interno que genera esa respuesta no se presenta como una secuencia de reglas fácilmente interpretable.

Frente a estos modelos, los modelos interpretables o de caja blanca tienen una estructura que permite comprender de forma más directa cómo se obtiene una predicción. La interpretación no se añade únicamente después de entrenar el modelo, sino que forma parte de su propio funcionamiento: sus parámetros, reglas o condiciones pueden examinarse y relacionarse con las variables de entrada. Por ejemplo, en un modelo lineal se puede estudiar el peso asociado a cada característica, mientras que en un sistema basado en reglas se puede seguir qué condiciones se han cumplido para llegar a una salida concreta. Esta transparencia facilita analizar qué variables intervienen en el resultado, si su influencia es razonable y si el comportamiento del modelo coincide con lo esperado en el problema estudiado [11].

La elección entre modelos interpretables y modelos de caja negra suele plantear un compromiso entre capacidad de representación e interpretabilidad. Los modelos más complejos pueden capturar relaciones no lineales difíciles de describir de forma simple, pero sus decisiones suelen ser menos transparentes. En cambio, los modelos interpretables pueden ser más fáciles de analizar, aunque no siempre alcanzan el mismo rendimiento en todos los problemas. No obstante, este compromiso no debe entenderse como una regla absoluta: en contextos donde la explicación del resultado es

¹[https://en.wikipedia.org/wiki/Neural_network_\(machine_learning\)](https://en.wikipedia.org/wiki/Neural_network_(machine_learning))

²https://en.wikipedia.org/wiki/Random_forest

³<https://openai.com/chatgpt/>

importante, es recomendable valorar primero si un modelo interpretable puede ofrecer un comportamiento adecuado antes de recurrir a modelos más opacos [12].

3.4.2. Clasificadores

En este trabajo se consideran dos clasificadores interpretables: regresión logística⁴ y árbol de decisión⁵. Ambos parten de la misma idea general: reciben una muestra representada por sus características y asignan una clase de salida. Sin embargo, cada uno aprende esa relación de una forma distinta.

Regresión logística. La regresión logística es un modelo lineal de clasificación. Aunque su nombre pueda sugerir una tarea de regresión, se utiliza para estimar la probabilidad de pertenecer a una clase. Para ello combina las características de entrada mediante una suma ponderada y transforma el resultado en una probabilidad. En el caso binario, esta idea puede expresarse como:


$$p(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b)$$

Ecuación 3.1: Probabilidad estimada por una regresión logística binaria.

donde $\mathbf{x}$ representa las características de la muestra, $\mathbf{w}$ los pesos aprendidos por el modelo, b el sesgo y σ la función logística, que convierte la puntuación del modelo en un valor entre 0 y 1. Esta formulación corresponde al caso binario, en el que solo existen dos clases posibles. En problemas con tres o más clases, como ocurre al distinguir entre varias emociones, la regresión logística se extiende calculando una puntuación para cada clase y seleccionando aquella con mayor probabilidad [16].

⁴https://en.wikipedia.org/wiki/Logistic_regression

⁵https://en.wikipedia.org/wiki/Decision_tree_learning



(a) Regresión logística binaria. Fuente: [18].

(b) Regresión logística multiclase. Fuente: [19].

Figura 3.4: Comparación entre regresión logística binaria y multiclase.

Árbol de decisión. Un árbol de decisión clasifica las muestras mediante una secuencia de reglas. Su estructura está formada por nodos, ramas y hojas: en cada nodo se evalúa una condición sobre una característica, cada rama representa el resultado de esa condición y cada hoja contiene la clase asignada. Por ejemplo, el modelo puede dividir primero las muestras según el valor de una característica concreta y, después, seguir refinando la decisión con nuevas condiciones.




Figura 3.5: Ejemplo de estructura de árbol de decisión. Fuente: [4].

Esta forma de funcionamiento hace que el modelo sea fácil de recorrer e interpretar, ya que la predicción puede explicarse como un camino desde la raíz del árbol hasta una hoja final. Además, a diferencia de un modelo estrictamente lineal, un árbol puede

capturar relaciones no lineales entre características sin exigir una transformación previa de los datos. Su principal limitación es que, si crece demasiado, puede ajustarse en exceso al conjunto de entrenamiento y perder capacidad de generalización [11].

3.4.3. Estrategia de evaluación y validación cruzada

La evaluación de un clasificador debe estimar cómo se comportará ante datos que no ha utilizado durante el entrenamiento. Si solo se mide el rendimiento sobre los mismos ejemplos con los que se ajusta el modelo, el resultado puede ser demasiado optimista, ya que el modelo puede haber aprendido particularidades del conjunto de entrenamiento en lugar de patrones generales. Por ello, en aprendizaje supervisado se distingue entre el ajuste del modelo y la estimación de su capacidad de generalización.

La forma más básica de plantear esta evaluación consiste en separar los datos en dos partes: un conjunto de entrenamiento, utilizado para ajustar el modelo, y un conjunto de prueba, reservado para medir su comportamiento sobre ejemplos no vistos. Esta separación permite simular la situación real en la que el clasificador recibe una nueva muestra y debe asignarle una clase sin haberla usado previamente para aprender.

La validación cruzada *k-fold*⁶ extiende esta idea de separación entre entrenamiento y prueba. En lugar de realizar una única división, el conjunto de datos se divide en k particiones o *folds*. En cada iteración, el modelo se entrena con $k - 1$ particiones y se evalúa con la partición restante. Al repetir el proceso hasta que todos los *folds* han actuado como conjunto de prueba, se obtiene una estimación media del comportamiento del modelo y de su variabilidad entre particiones [20].

⁶[https://en.wikipedia.org/wiki/Cross-validation_\(statistics\)](https://en.wikipedia.org/wiki/Cross-validation_(statistics))




Figura 3.6: Esquema de validación cruzada k -fold. Fuente: [5].

$$\overline{M}_{CV} = \frac{1}{k} \sum_{i=1}^k M_i$$

Ecuación 3.2: Promedio de una métrica en validación cruzada k -fold.

donde $\overline{M}_{CV}$ representa el rendimiento medio estimado mediante validación cruzada, k es el número de particiones y M_i es el valor de la métrica obtenido en el $fold$ i . Esta expresión resume la idea de evaluar el modelo varias veces y combinar los resultados en una medida global.

En problemas de clasificación con varias clases, como el reconocimiento de emociones, es importante que cada partición mantenga una distribución de clases similar a la del conjunto completo. La validación cruzada estratificada busca precisamente conservar proporciones parecidas de cada clase en los distintos $fold$ s. De esta forma se reduce el riesgo de evaluar el modelo en particiones poco representativas, por ejemplo con muy pocas muestras de una emoción concreta [20].

En señales de EEG, además de la distribución de clases, debe tenerse en cuenta la dependencia entre muestras de un mismo sujeto. Si segmentos o muestras procedentes de la misma persona aparecen simultáneamente en entrenamiento y prueba, el modelo puede aprovechar características propias del sujeto en lugar de aprender patrones que generalicen a personas no vistas. Este problema puede producir estimaciones de

rendimiento artificialmente altas, por lo que en estudios con múltiples muestras por individuo es recomendable que la separación entre entrenamiento y prueba respete la agrupación por sujeto [21].

Esta idea está relacionada con la fuga de información, o *data leakage*⁷, que ocurre cuando durante el entrenamiento o la selección del modelo se utiliza información que no estaría disponible en una predicción real. En este contexto no solo importa cómo se dividen los datos, sino también cómo se aplican los pasos previos al modelo. Transformaciones como la normalización, la selección de características o el ajuste de configuraciones deben calcularse utilizando únicamente la parte de entrenamiento de cada partición y aplicarse después sobre la parte de prueba [22].

La validación cruzada también puede utilizarse para comparar distintas configuraciones de un modelo y seleccionar aquella que obtiene mejor comportamiento medio. Sin embargo, esta selección debe separarse conceptualmente de la evaluación final, ya que usar los mismos resultados para escoger el modelo y estimar su rendimiento puede introducir una estimación demasiado optimista del error. Por tanto, la estrategia de evaluación debe diseñarse de forma que mida la capacidad de generalización del modelo y no solo su adaptación a una partición concreta de los datos.

3.4.4. Métricas

Una vez definido cómo se separan los datos para entrenar y evaluar el modelo, es necesario escoger métricas que resuman la relación entre las etiquetas reales y las etiquetas predichas. En un problema de clasificación multiclase, como el reconocimiento de emociones, estas métricas no solo indican cuántas muestras se han clasificado correctamente, sino también qué clases se confunden entre sí y si el rendimiento es equilibrado entre emociones. Las medidas descritas a continuación son habituales en tareas de clasificación y están disponibles en bibliotecas de aprendizaje automático como scikit-learn [23].

- **Matriz de confusión.** La matriz de confusión organiza las predicciones comparando, para cada muestra, la clase real con la clase asignada por el modelo. En el caso binario, esta matriz permite distinguir cuatro situaciones: los verdaderos positivos (TP), que son muestras positivas clasificadas correctamente; los verdaderos negativos (TN), que son muestras negativas clasificadas

⁷[https://en.wikipedia.org/wiki/Leakage_\(machine_learning\)](https://en.wikipedia.org/wiki/Leakage_(machine_learning))

correctamente; los falsos positivos (FP), que son muestras negativas clasificadas erróneamente como positivas; y los falsos negativos (FN), que son muestras positivas clasificadas erróneamente como negativas [6].

		Actual Condition		
		FALSE	TRUE	
Predicted Condition	FALSE	TN	FN	Predicted Negative
	TRUE	FP	TP	Predicted Positive
		Actual Negative	Actual Positive	

Figura 3.7: Ejemplo de matriz de confusión binaria. Fuente: [6].

En clasificación multiclase, la idea se extiende a una matriz con tantas filas y columnas como clases tenga el problema. Las filas representan normalmente las clases reales y las columnas las clases predichas. Los valores de la diagonal principal corresponden a aciertos, mientras que los valores fuera de la diagonal muestran errores entre clases concretas. Esta representación es especialmente útil cuando interesa saber, por ejemplo, si dos emociones tienden a confundirse más que el resto [23].

- **Exactitud o *accuracy*.** La exactitud mide la proporción de muestras clasificadas correctamente respecto al total. Es una métrica sencilla y fácil de interpretar, pero puede ocultar problemas cuando las clases no están equilibradas, ya que un modelo puede obtener una exactitud alta favoreciendo a la clase más frecuente. En clasificación multiclase puede expresarse a partir de la matriz de confusión:

$$\text{Accuracy} = \frac{\sum_{c=1}^C n_{cc}}{\sum_{i=1}^C \sum_{j=1}^C n_{ij}}$$

Ecuación 3.3: Exactitud en clasificación multiclase a partir de la matriz de confusión.

donde C es el número de clases, n_{cc} representa los aciertos de la clase c y n_{ij} indica el número de muestras cuya clase real es i y cuya clase predicha es j .

- **Precisión, recall y F1-score.** Para analizar el comportamiento por clase se pueden calcular métricas considerando cada emoción frente al resto. La precisión mide la fiabilidad de las predicciones realizadas para una clase: de todas las muestras que el modelo asigna a esa clase, indica qué proporción es correcta. El *recall*, también llamado sensibilidad, mide la capacidad del modelo para detectar una clase: de todas las muestras que realmente pertenecen a esa clase, indica qué proporción ha sido clasificada correctamente. El F1-score combina ambas medidas mediante una media armónica, por lo que penaliza los casos en los que una de las dos es baja [23].

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = 2 \cdot \frac{P_c \cdot R_c}{P_c + R_c}$$

Ecuación 3.4: Precisión, recall y F1-score para una clase c .

donde P_c es la precisión de la clase c , R_c es su *recall*, TP_c son los verdaderos positivos, FP_c los falsos positivos y FN_c los falsos negativos de esa clase.

- **F1 macro.** En problemas con varias clases, el F1-score puede calcularse para cada clase y después promediarse. El promedio macro asigna el mismo peso a todas las clases, independientemente del número de muestras que tenga cada una. Por ello resulta adecuado cuando se quiere valorar si el modelo funciona de forma equilibrada entre las distintas emociones, sin que una clase con más ejemplos domine el resultado global [23].

$$F1_{\text{macro}} = \frac{1}{C} \sum_{c=1}^C F1_c$$

Ecuación 3.5: F1 macro como promedio no ponderado del F1-score por clase.

- **Media y desviación entre particiones.** Cuando las métricas se calculan dentro de una validación cruzada, cada *fold* produce un valor distinto. La media resume el rendimiento esperado del modelo y la desviación estándar indica la variabilidad entre particiones. Una desviación elevada puede señalar que el resultado depende mucho de qué sujetos o muestras quedan en cada partición, por lo que aporta información complementaria al valor medio.

3.5. Técnicas de explicación

Para analizar el comportamiento de los modelos entrenados, en este trabajo se emplean dos tipos de técnicas de explicación: los valores *SHapley Additive exPlanations* (SHAP) y los mapas topográficos. Ambas permiten examinar, desde perspectivas distintas, qué información de la señal de EEG tiene más peso en las decisiones del clasificador.

Los mapas topográficos, o *topomaps*, permiten representar información de la señal de EEG sobre una distribución espacial similar a la posición real de los electrodos en el cráneo. De esta forma, es posible visualizar qué zonas presentan mayor actividad o mayor importancia dentro del análisis realizado. En el reconocimiento de emociones, es habitual generar un mapa por cada banda espectral analizada, ya que la importancia de cada región puede variar en función de la frecuencia. Además, los valores representados pueden interpretarse en valor absoluto, indicando la magnitud de la contribución de cada zona, o con signo, mostrando si esa contribución empuja hacia una clase o la aleja. Los *topomaps* permiten comparar visualmente los patrones asociados a alegría, tristeza y estado neutro a lo largo de las distintas bandas espectrales.




Figura 3.8: Ejemplo de topomaps por banda espectral para la clase alegría.

Por otro lado, SHAP es una técnica de explicación basada en la teoría de juegos cooperativos que asigna a cada característica un valor según cuánto contribuye a la predicción del modelo. Su principal ventaja es que ofrece explicaciones tanto a nivel global, mostrando qué variables son más relevantes en general, como a nivel individual, indicando en qué dirección empuja cada característica una predicción concreta. En modelos lineales, este valor puede calcularse de forma exacta a partir de los coeficientes del modelo, sin necesidad de aproximaciones [24].




Figura 3.9: Ejemplo de importancia de características mediante valores SHAP.

Bibliografía

- [1] Psycholab. Lóbulos cerebrales para principiantes, 2021. <https://www.psycholab.com/lobulos-cerebrales-para-principiantes/>.
- [2] Carlos Novo, Leticia Chacón Gutiérrez, and José Alberto Barradas Bribiesca. Mapeo electroencefalográfico y neurofeedback, 2010. https://www.researchgate.net/figure/Figura-3-Sistema-Internacional-10-20-para-la-colocacion-de-los-electrodos_fig2_282294960.
- [3] Jennifer Delgado. Lista de 290 emociones y sentimientos: cómo diferenciarlos, 2024. <https://rinconpsicologia.com/lista-de-emociones-y-sentimientos/>.
- [4] adrigm. Crear un adivinador, 2013. <https://www.genbeta.com/desarrollo/crear-un-adivinador>.
- [5] Gladys Andrea Rodríguez Guerrero. Cross-validation, 2021. <https://gladysandrea-rodriguez.medium.com/cross-validation-11e9ea688506>.
- [6] Ben Hayes. Demystifying the confusion matrix, 2018. <https://benhay.es/posts/demystifying-confusion-matrix/>.
- [7] Mayo Clinic. Electroencefalografía (EEG), 2024. <https://www.mayoclinic.org/es/tests-procedures/eeg/about/pac-20393875>.
- [8] Soraia M. Alarcão and Manuel J. Fonseca. Emotions recognition using eeg signals: A survey. *IEEE Transactions on Affective Computing*, 10(3):374–393, 2019. <https://ieeexplore.ieee.org/abstract/document/7946165>.
- [9] Isaac Martín de Diego, Ángel Serrano, Cristina Conde, and Enrique Cabello. Técnicas de reconocimiento automático de emociones. *Teoría de la Educación: Educación y Cultura en la Sociedad de la Información*, 7(2):92–106, 2006. <https://revistas.usal.es/tres/index.php/eks/article/view/19413/19414>.

- [10] Lin Shu, Jinyan Xie, Mingyue Yang, Ziyi Li, Zhenqi Li, Dan Liao, Xiangmin Xu, and Xinyi Yang. A review of emotion recognition using physiological signals. *Sensors*, 18(7):2074, 2018. <https://www.mdpi.com/1424-8220/18/7/2074>.
- [11] Christoph Molnar. *Interpretable Machine Learning*. 2 edition, 2022. <https://christophm.github.io/interpretable-ml-book/>.
- [12] Cynthia Rudin. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1:206–215, 2019. <https://www.nature.com/articles/s42256-019-0048-x>.
- [13] G. H. Klem, H. O. Lüders, H. H. Jasper, and C. Elger. The ten-twenty electrode system of the international federation. the international federation of clinical neurophysiology. *Electroencephalography and Clinical Neurophysiology. Supplement*, 52:3–6, 1999.
- [14] Robert Oostenveld and Peter Praamstra. The five percent electrode system for high-resolution eeg and erp measurements. *Clinical Neurophysiology*, 112(4):713–719, 2001. <https://www.sciencedirect.com/science/article/abs/pii/S1388245700005277>.
- [15] Arjun, Aniket Singh Rajpoot, and Mahesh Raveendranatha Panicker. Subject independent emotion recognition using EEG signals employing attention driven neural networks. *Biomedical Signal Processing and Control*, 75:103547, 2022. <https://www.sciencedirect.com/science/article/abs/pii/S1746809422000696>.
- [16] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, New York, 2006.
- [17] Fabien Lotte, Marco Congedo, Anatole Lécuyer, Fabrice Lamarche, and Bruno Arnaldi. A review of classification algorithms for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, 4(2):R1–R13, 2007. <https://iopscience.iop.org/article/10.1088/1741-2560/4/2/R01>.
- [18] Ignacio Moreno Hojas. Regresión logística en python, s. f. <https://www.statdeveloper.com/regresion-logistica-en-python/>.
- [19] Codificando Bits. Qué es la regresión multiclase, s. f. <https://codificandobits.com/blog/regresion-multiclase/>.

- [20] Ron Kohavi. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence*, pages 1137–1145. Morgan Kaufmann, 1995. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>.
- [21] Geoffrey Brookshire, Jake Kasper, Nicholas M. Blauch, Yunan Charles Wu, Ryan Glatt, David A. Merrill, Spencer Gerrol, Keith J. Yoder, Colin Quirk, and Ché Lucero. Data leakage in deep learning studies of translational EEG. *Frontiers in Neuroscience*, 18:1373515, 2024. <https://doi.org/10.3389/fnins.2024.1373515>.
- [22] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):15, 2012. <https://doi.org/10.1145/2382577.2382579>.
- [23] scikit-learn developers. Metrics and scoring: Quantifying the quality of predictions, 2026. https://scikit-learn.org/stable/modules/model_evaluation.html.
- [24] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017. <https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>.
- [25] Ante Topic and Mladen Russo. Emotion recognition based on EEG feature maps through deep learning network. *Engineering Science and Technology, an International Journal*, 24(6):1442–1454, 2021. <https://www.sciencedirect.com/science/article/pii/S2215098621000768>.